



รายงาน กระบวนทัศน์ใหม่ของการรู้จำรูปแบบ

จัดทำโดย

นายชยุตม์ อยู่เจริญกิจ

รหัสนักศึกษา 67543206046-4

กลุ่มเรียน ENGCE408_SEC1

เสนอ

ผู้ช่วยศาสตราจารย์ ดร.สมนึก สุระธง

รายงานนี้เป็นส่วนหนึ่งของวิชา

ENGCE 408

(Introduction to Pattern Recognition)

หลักสูตรวิศวกรรมศาสตรบัณฑิต

สาขาวิศวกรรมไฟฟ้า (วิศวกรรมคอมพิวเตอร์)

คณะวิศวกรรมศาสตร์

มหาวิทยาลัยเทคโนโลยีราชมงคลล้านนา เชียงใหม่

ภาคเรียนที่ 1 ปีการศึกษา 2569

คำนำ

รายงานฉบับนี้จัดทำขึ้นเพื่อเป็นส่วนหนึ่งของรายวิชา ENGCE 408 Introduction to Pattern Recognition หลักสูตรวิศวกรรมศาสตรบัณฑิต สาขาวิศวกรรมไฟฟ้า (วิศวกรรมคอมพิวเตอร์) คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเทคโนโลยีราชมงคลล้านนา เชียงใหม่ ประจำปีภาคเรียนที่ 1 ปีการศึกษา 2569 โดยมีวัตถุประสงค์เพื่อศึกษาเปรียบเทียบประสิทธิภาพของแบบจำลองโครงข่ายประสาทเทียมสองกระบวนการวนทัศน์ ได้แก่ แบบจำลองความจำระยะสั้นยาว (Long Short-Term Memory: LSTM) และแบบจำลองภาษาเบิร์ต (Bidirectional Encoder Representations from Transformers: BERT) ในการจำแนกความคิดเห็น ภาพยนตร์จากชุดข้อมูล IMDb

เนื้อหาภายในรายงานประกอบด้วย ความเป็นมาและความสำคัญของปัญหา ทฤษฎีที่เกี่ยวข้อง วิธีการดำเนินงานและการทดลอง ผลการทดลองและการวิเคราะห์ผล และสรุปผลการทดลอง โดยผลการทดลองพบว่าแบบจำลอง BERT ให้ค่าความถูกต้องร้อยละ 85.60 สูงกว่าแบบจำลอง LSTM ที่ร้อยละ 55.20

ผู้จัดทำขอขอบพระคุณ ผู้ช่วยศาสตราจารย์ ดร.สมนึก สุระธง อาจารย์ประจำรายวิชา ที่กรุณาให้คำปรึกษา และข้อเสนอแนะอันเป็นประโยชน์อย่างยิ่งต่อการจัดทำรายงานฉบับนี้

ผู้จัดทำหวังเป็นอย่างยิ่งว่ารายงานฉบับนี้จะเป็นประโยชน์แก่ผู้สนใจศึกษาด้านการประมวลผลภาษาธรรมชาติ และการรู้จำรูปแบบ หากมีข้อผิดพลาดประการใด ผู้จัดทำขอน้อมรับไว้และขออภัยมา ณ โอกาสนี้

นายชยุตม์ อยู่เจริญกิจ
รหัสนักศึกษา 67543206046-4
กันยายน 2569

สารบัญ

คำนำ	ก
สารบัญ	๗
1. ความเป็นมาและความสำคัญของปัญหา	1
2. ทฤษฎีที่เกี่ยวข้อง	2
2.1 โครงข่ายประสาทแบบดั้งเดิมสำหรับการประมวลผลข้อมูลลำดับ (Sequential Models)	2
2.1.1 โครงข่ายประสาทแบบวนซ้ำ (Recurrent Neural Network: RNN)	2
2.1.2 โครงข่ายประสาทแบบจดจำระยะสั้นยาว (Long Short-Term Memory: LSTM)	2
2.2 สถาปัตยกรรมทรานส์ฟอร์เมอร์ (Transformer Architecture)	3
2.2.2 กลไกความใส่ใจหลายหัว (Multi-Head Self-Attention)	3
2.2.3 การเข้ารหัสตำแหน่ง (Positional Encoding)	3
2.3 แบบจำลองภาษาขนาดใหญ่และการปรับแต่งเฉพาะทาง (LLM and Fine-tuning)	4
2.3.1 แบบจำลองภาษา BERT (Bidirectional Encoder Representations from Transformers)	4
2.3.2 การปรับแต่งเฉพาะทาง (Fine-tuning)	4
3. วิธีการแก้ปัญหาและการทดลอง	5
3.2.1 การทำความสะอาดข้อมูล (Text Cleaning)	6
3.2.2 การจำกัดความยาวลำดับ (Sequence Truncation and Padding)	6
3.2.3 การสร้างเวกเตอร์แทนคำเฉพาะแบบจำลอง (Model-specific Input Representation)	6
3.3.2 แบบจำลองภาษาเบิร์ต (BERT Classifier) [3]	7
3.4 การกำหนดค่าไฮเปอร์พารามิเตอร์และสภาพแวดล้อมในการคำนวณ	7
3.5 เกณฑ์การประเมินประสิทธิภาพและตัวชี้วัด (Evaluation Metrics)	8
3.5.1 มิติด้านประสิทธิภาพการรู้จำรูปแบบ (Pattern Recognition Metrics)	9
3.5.2 มิติด้านประสิทธิภาพการคำนวณเชิงวิศวกรรม (Computational Efficiency Metrics)	9
4. ผลการทดลองและการวิเคราะห์ผล	10

สารบัญ (ต่อ)

4.1 ผลลัพธ์เชิงตัวเลขและตัวชี้วัดประสิทธิภาพ (Quantitative Performance Evaluation)	10
4.2 การวิเคราะห์อัตราการลู่เข้าและฟังก์ชันสูญเสีย (Loss Convergence Analysis)	11
4.2.1 พฤติกรรมการเรียนรู้ของแบบจำลอง LSTM.....	11
4.2.2 พฤติกรรมการเรียนรู้ของแบบจำลอง BERT	11
4.3 การวิเคราะห์ประสิทธิภาพเชิงการคำนวณและความคุ้มค่า (Computational Efficiency and Trade-offs)	12
4.4 การวิเคราะห์ความผิดพลาดและข้อจำกัดเชิงโครงสร้าง (Qualitative and Error Analysis)	12
4.4.1 การจัดการกับบริบทระยะไกล (Long-term Dependencies)	12
4.4.2 การเข้ารหัสบริบทแบบสองทิศทางที่แท้จริง (Bidirectional Representation)	12
5. สรุปผลการทดลอง (Conclusion).....	13
เอกสารอ้างอิง	ง

1. ความเป็นมาและความสำคัญของปัญหา

ปัจจุบันข้อมูลข้อความบนระบบสารสนเทศและสื่อออนไลน์มีปริมาณเพิ่มสูงขึ้นอย่างมหาศาล ส่งผลให้เทคโนโลยีการประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) เข้ามามีบทบาทสำคัญในการพัฒนาระบบอัตโนมัติหลากหลายด้าน เช่น การวิเคราะห์ความรู้สึกของผู้ใช้งาน (Sentiment Analysis) การค้นคืนสารสนเทศ (Information Retrieval) และการพัฒนาระบบสนทนาอัจฉริยะ (Conversational AI) เพื่อเพิ่มประสิทธิภาพและความแม่นยำในการดำเนินงาน

อย่างไรก็ตาม การประมวลผลข้อมูลลำดับในอดีตมักอาศัยโครงข่ายประสาทแบบ Recurrent Neural Network (RNN) และ Long Short-Term Memory (LSTM) [1] ซึ่งยังมีข้อจำกัดสำคัญทางโครงสร้าง กล่าวคือ โมเดลจำเป็นต้องประมวลผลข้อมูลตามลำดับเวลา ทำให้ไม่สามารถประมวลผลแบบขนาน (Parallel Processing) ได้อย่างเต็มที่ ส่งผลให้การฝึกโมเดลใช้เวลานานและขยายขนาดตามปริมาณข้อมูลได้ยาก อีกทั้งยังมีข้อจำกัดในการจดจำและเชื่อมโยงบริบทที่มีความยาวสูง (Long-term Dependencies) ข้อมูลสำคัญจากส่วนต้นจึงมักสูญหายหรือถูกลดทอนประสิทธิภาพลง

สถาปัตยกรรม Transformer [2] จึงถูกนำเสนอขึ้นเพื่อแก้ไขข้อจำกัดดังกล่าว โดยเปลี่ยนมาใช้กลไก Self-Attention ร่วมกับ Positional Encoding ทำให้โมเดลสามารถคำนวณความสัมพันธ์ระหว่างทุกตำแหน่งในประโยคได้พร้อมกันโดยตรงแบบคู่ขนาน ซึ่งกลายเป็นรากฐานสำคัญของการพัฒนาโมเดลภาษาขนาดใหญ่ (Large Language Models: LLM) เช่น BERT เป็นต้น ซึ่งสามารถนำไปปรับแต่งให้เหมาะกับงานเฉพาะทาง (Fine-tuning) ได้

ด้วยเหตุนี้ ผู้จัดทำจึงได้ศึกษาและจัดทำรายงานฉบับนี้ขึ้น เพื่อทำความเข้าใจวิวัฒนาการ โครงสร้างการทำงาน และหลักการทางเทคนิคของสถาปัตยกรรมดังกล่าว เพื่อใช้เป็นองค์ความรู้พื้นฐานในการประยุกต์ใช้และพัฒนาเทคโนโลยีโมเดลภาษาปัญญาประดิษฐ์ต่อไป

2. ทฤษฎีที่เกี่ยวข้อง

2.1 โครงข่ายประสาทแบบดั้งเดิมสำหรับการประมวลผลข้อมูลลำดับ (Sequential Models)

ก่อนการพัฒนาสถาปัตยกรรมทรานส์ฟอร์มเมอร์ การประมวลผลข้อมูลที่มีลักษณะเป็นลำดับต่อเนื่อง (Sequential Data) เช่น ข้อความหรือสัญญาณเสียง นิยมใช้โครงข่ายประสาทเทียมที่ออกแบบมาเพื่อจดจำลำดับ ดังนี้:

2.1.1 โครงข่ายประสาทแบบวนซ้ำ (Recurrent Neural Network: RNN)

มีจุดเด่นด้านการส่งผ่านสถานะซ่อนเร้น (Hidden State: h_t) จากขั้นตอนเวลาก่อนหน้า (h_{t-1}) เพื่อใช้เป็นหน่วยความจำร่วมกับข้อมูลนำเข้าปัจจุบัน (x_t) โดยมีสมการการปรับปรุงสถานะและการคำนวณผลลัพธ์ ดังนี้:

$$h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1} + b_h)$$

$$o_t = W_{hy}h_t + b_y$$

อย่างไรก็ตาม โครงสร้างแบบ RNN ประสบปัญหาการหายไปของเกรเดียนต์ (Vanishing Gradient) เมื่อประมวลผลลำดับข้อมูลที่มีความยาวสูง ส่งผลให้ไม่สามารถจดจำบริบทที่อยู่ห่างกันได้

2.1.2 โครงข่ายประสาทแบบจดจำระยะสั้นยาว (Long Short-Term Memory: LSTM)

ถูกพัฒนาขึ้นโดย Hochreiter และ Schmidhuber [1] เพื่อแก้ไขปัญหา Vanishing Gradient ของ RNN โดยเพิ่มสายส่งผ่านข้อมูลหลักที่เรียกว่า สถานะของเซลล์ (Cell State: c_t) ควบคู่กับกลไกควบคุมการไหลของข้อมูลผ่านเกต (Gates) จำนวน 3 ส่วน ได้แก่ Forget Gate (f_t), Input Gate (i_t) และ Output Gate (o_t) แม้ LSTM จะสามารถรักษาข้อมูลระยะไกลได้มีประสิทธิภาพมากขึ้น แต่กระบวนการคำนวณยังคงต้องดำเนินไปตามลำดับเวลาที่ละขั้นตอน (Step-by-step) ซึ่งก่อให้เกิดปัญหาคอขวดและไม่สามารถประมวลผลแบบขนาน (Parallel Processing) ได้อย่างสมบูรณ์

2.2 สถาปัตยกรรมทรานส์ฟอร์เมอร์ (Transformer Architecture)

Vaswani และคณะ [2] ได้นำเสนอสถาปัตยกรรมทรานส์ฟอร์เมอร์ ซึ่งยกเลิกโครงสร้างแบบวนซ้ำทั้งหมด และเปลี่ยนมาใช้กลไกความใส่ใจตนเอง (Self-Attention Mechanism) เป็นแกนหลักในการประมวลผลลำดับข้อมูล โครงสร้างของสถาปัตยกรรมประกอบด้วยองค์ประกอบสำคัญ ดังนี้:

2.2.1 กลไกความใส่ใจแบบสเกลดอทโปรดักต์ (Scaled Dot-Product Attention)

เป็นการคำนวณความสัมพันธ์ระหว่างคู่โทเคนทั้งหมดในประโยค โดยแปลงข้อมูลเป็นเวกเตอร์ 3 ชุด ได้แก่ คำค้นหา (Query: Q), กุญแจ (Key: K) และค่าข้อมูล (Value: V) คำนวณผ่านสมการ:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

โดยมีการหารด้วยสเกล $\sqrt{d_k}$ (สแควร์รูทของมิติเวกเตอร์กุญแจ) เพื่อควบคุมไม่ให้ผลคูณสเกลาร์มีค่าสูงเกินไปจนทำให้เกรเดียนต์ของฟังก์ชัน Softmax มีค่าน้อยเกินไป (Vanishing Gradient)

2.2.2 กลไกความใส่ใจหลายหัว (Multi-Head Self-Attention)

เป็นการแปลงเชิงเส้น (Projection) ของเวกเตอร์ Q, K, V ออกเป็นหลายชุดย่อย (Heads) เพื่อให้โมเดลสามารถเรียนรู้ความสัมพันธ์ของบริบทในมิติและแง่มุมที่แตกต่างกันได้พร้อมกัน จากนั้นจึงนำผลลัพธ์จากแต่ละหัวมารวมกัน (Concatenate) และผ่านการแปลงเชิงเส้น (Linear Projection)

2.2.3 การเข้ารหัสตำแหน่ง (Positional Encoding)

เนื่องจากสถาปัตยกรรมทรานส์ฟอร์เมอร์ประมวลผลข้อมูลทุกโทเคนพร้อมกันในรูปแบบขนาน จึงไม่มีลำดับเวลาตามธรรมชาติ จำเป็นต้องเพิ่มข้อมูลตำแหน่งของแต่ละโทเคนเข้าไปยังเวกเตอร์นำเข้า (Input Embedding) ผ่านฟังก์ชันไซน์และโคไซน์ (Sinusoidal Positional Encoding) ดังสมการ:

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$

เมื่อ pos คือตำแหน่งของโทเคนในลำดับ และ i คือดัชนีมิติภายในเวกเตอร์

2.3 แบบจำลองภาษาขนาดใหญ่และการปรับแต่งเฉพาะทาง (LLM and Fine-tuning)

การขยายขนาดสถาปัตยกรรมทรานส์ฟอร์มเมอร์ร่วมกับการฝึกฝนบนคลังข้อมูลขนาดใหญ่แบบเรียนรู้ด้วยตนเอง (Self-Supervised Pre-training) นำไปสู่การพัฒนาแบบจำลองภาษาขนาดใหญ่ (Large Language Models: LLM) ที่มีประสิทธิภาพสูง

2.3.1 แบบจำลองภาษา BERT (Bidirectional Encoder Representations from Transformers)

นำเสนอโดย Devlin และคณะ [3] โดยใช้โครงสร้างเฉพาะส่วนตัวเข้ารหัส (Encoder-only) ของทรานส์ฟอร์มเมอร์ มีจุดเด่นด้านการเรียนรู้บริบทของประโยคแบบสองทิศทาง (Bidirectional) พร้อมกัน ผ่านภารกิจก่อนการใช้งานจริง 2 รูปแบบ ได้แก่ Masked Language Model (MLM) และ Next Sentence Prediction (NSP)

2.3.2 การปรับแต่งเฉพาะทาง (Fine-tuning)

เป็นกระบวนการถ่ายโอนการเรียนรู้ (Transfer Learning) โดยนำแบบจำลองภาษาที่ผ่านการฝึกฝนทั่วไปมาแล้ว (Pre-trained Model) มาต่อเติมชั้นประมวลผลผลลัพธ์เฉพาะทาง (Task-specific Layer เช่น Classification Head) จากนั้นทำการปรับปรุงค่าน้ำหนักด้วยชุดข้อมูลเฉพาะงาน เช่น การวิเคราะห์ความรู้สึก (Sentiment Analysis) หรือการจำแนกประเภทข้อความ (Text Classification) วิธีนี้ช่วยประหยัดเวลาทรัพยากรคอมพิวเตอร์ และให้ความแม่นยำสูงแม้มีข้อมูลตัวอย่างจำนวนจำกัด

3. วิธีการแก้ปัญหาและการทดลอง

เพื่อพิสูจน์เชิงประจักษ์ถึงการเปลี่ยนผ่านของกระบวนการทัศน์ในระบบการรู้จำรูปแบบ (Pattern Recognition) จากการประมวลผลข้อมูลตามลำดับเวลาไปสู่การประมวลผลแบบขนานด้วยกลไกความใส่ใจตนเอง (Self-Attention) การดำเนินงานในรายงานฉบับนี้จึงกำหนดระเบียบวิธีวิจัยเชิงทดลองเพื่อเปรียบเทียบประสิทธิภาพระหว่างโครงข่ายประสาทแบบจดจำระยะสั้นยาว (Long Short-Term Memory: LSTM) ในฐานะตัวแทนของกระบวนการทัศน์เดิม กับแบบจำลองภาษาเบิร์ต (BERT) ในฐานะตัวแทนของกระบวนการทัศน์ใหม่ ภายใต้ภารกิจการจำแนกประเภทข้อความและการวิเคราะห์ความรู้สึก (Sentiment Analysis) โดยมีขั้นตอนการดำเนินงานเชิงวิศวกรรมอย่างเป็นระบบดังต่อไปนี้:

3.1 กรอบแนวคิดและกระบวนการดำเนินงาน (Experimental Framework)

ระเบียบวิธีวิจัยถูกออกแบบเป็นกระบวนการประมวลผลแบบครบวงจร (End-to-End Pipeline) เพื่อให้สามารถควบคุมสภาพแวดล้อมและตัวแปรในการทดลองได้อย่างเที่ยงตรง โดยแบ่งกระบวนการออกเป็น 5 ลำดับขั้น ได้แก่:

1. การจัดเตรียมและจัดสรรชุดข้อมูล (Dataset Preparation and Splitting)
2. การแปลงสภาพข้อมูลและการสร้างโทเคน (Data Preprocessing and Tokenization)
3. การออกแบบสถาปัตยกรรมแบบจำลอง (Model Architecture Design)
4. การฝึกสอนและการปรับจูนค่าน้ำหนัก (Model Training and Fine-tuning)
5. การวัดผลและประเมินประสิทธิภาพ (Performance Evaluation)

3.2 ชุดข้อมูลและการประมวลผลขั้นต้น (Dataset and Preprocessing Pipeline)

การทดลองใช้ชุดข้อมูลความคิดเห็นภาพยนตร์ IMDb [4] สำหรับการจำแนกความรู้สึกแบบสองขั้ว (Binary Sentiment Classification) โดยกำหนดป้ายกำกับออกเป็น 2 กลุ่ม ได้แก่ ความคิดเห็นเชิงบวก (Positive: Class 1) และความคิดเห็นเชิงลบ (Negative: Class 0) โดยจัดสรรข้อมูลสำหรับการทดลองออกเป็น ชุดข้อมูลฝึกสอน (Training Set) จำนวน 2,000 ตัวอย่าง และชุดข้อมูลทดสอบวัดผลขั้นสุดท้าย (Test Set) จำนวน 500 ตัวอย่าง ภายใต้สัดส่วนของทั้งสองคลาสที่สมดุลกัน โดยกำหนดค่า seed เท่ากับ 42 ในขั้นตอนการสุ่มและจัดสรรชุดข้อมูล

3.2.1 การทำความสะอาดข้อมูล (Text Cleaning)

ดำเนินการตัดแท็ก HTML อักขระพิเศษที่ไม่เกี่ยวข้องกับการสื่อสารทางภาษา รวมถึงการจัดระเบียบช่องไฟของข้อความให้ได้มาตรฐานก่อนนำไปประมวลผล

3.2.2 การจำกัดความยาวลำดับ (Sequence Truncation and Padding)

กำหนดความยาวสูงสุดของข้อความไว้ที่ 128 โทเคน โดยข้อความที่มีความยาวเกินกว่าเกณฑ์จะถูกตัดส่วนท้ายออก และข้อความที่สั้นกว่าเกณฑ์จะได้รับการเติมเต็มด้วยโทเคนศูนย์ (Zero Padding) เพื่อรักษามิติของข้อมูลนำเข้าให้เท่ากันทุกชุดข้อมูล

3.2.3 การสร้างเวกเตอร์แทนคำเฉพาะแบบจำลอง (Model-specific Input Representation)

สำหรับแบบจำลอง LSTM จะแปลงข้อความเป็นลำดับดัชนีจำนวนเต็มตามชุดคำศัพท์ขนาด 30,522 คำ (vocabulary ของ bert-base-uncased) เพื่อส่งเข้าสู่ชั้น Embedding ในขณะที่แบบจำลอง BERT จะใช้กระบวนการแยกคำระดับหน่วยย่อย (Subword Tokenization) โดยแทรกโทเคนควบคุมโครงสร้าง [CLS] ไว้ที่ตำแหน่งแรกของประโยคเพื่อใช้เก็บข้อมูลบริบทภาพรวม และแทรกโทเคน [SEP] ไว้ที่ท้ายประโยคเพื่อระบุจุดสิ้นสุดข้อความ

3.3 โครงสร้างสถาปัตยกรรมแบบจำลองที่ใช้ในการทดลอง

3.3.1 แบบจำลองโครงข่ายประสาทแบบจดจำระยะสั้นยาว (LSTM Classifier) [1]

ใช้เป็นตัวแทนของกระบวนการตัดสินใจ ประกอบด้วยชั้น Embedding ขนาด 128 มิติ (จำนวนคำศัพท์ 30,522 คำ ตาม vocabulary ของ bert-base-uncased) ส่งผ่านข้อมูลไปยังชั้น LSTM ขนาด 128 หน่วยซ่อนเร้น (Hidden Units) โดยประมวลผลข้อมูลตามลำดับเวลาที่ละขั้นตอนผ่านกลไกสถานะของเซลล์ (C_t) และเกตควบคุม (f_t, i_t, o_t) จากนั้นถึงสถานะซ่อนเร้นสุดท้าย (h_T) ส่งต่อไปยังชั้นเชื่อมต่อแบบหนาแน่น (Dense Layer) และฟังก์ชัน Softmax เพื่อแปลงเป็นความน่าจะเป็นของคลาสผลลัพธ์

3.3.2 แบบจำลองภาษาเบิร์ต (BERT Classifier) [3]

ใช้เป็นตัวแทนของกระบวนการทัศน์ใหม่ โดยมีโครงสร้างหลักเป็น Transformer Encoder จำนวน 12 ชั้น และกลไก Multi-Head Self-Attention จำนวน 12 หัวประมวลผลคู่ขนาน โดยใช้ checkpoint สำเร็จรูป bert-base-uncased ผ่าน AutoTokenizer.from_pretrained และ AutoModelForSequenceClassification.from_pretrained ในส่วนการปรับแต่งเฉพาะงาน (Classification Head) จะดึงเวกเตอร์ผลลัพธ์จากตำแหน่งของโทเคน [CLS] ($h_{[CLS]}$) ขนาด 768 มิติ ออกมาผ่านชั้น Dropout ที่อัตราร้อยละ 10 เพื่อลดภาวะการเรียนรู้มากเกินไป (Overfitting) จากนั้นส่งผ่านชั้นเชื่อมต่อเชิงเส้น (Linear Projection) เพื่อลดรูปมิติลงเหลือ 2 มิติ และแปลงเป็นค่าความน่าจะเป็นด้วยฟังก์ชัน Softmax

3.4 การกำหนดค่าไฮเปอร์พารามิเตอร์และสภาพแวดล้อมในการคำนวณ

การทดลองดำเนินการด้วยภาษา Python บนเฟรมเวิร์ก PyTorch ร่วมกับไลบรารี Transformers ของ Hugging Face [5] โดยดำเนินการบน Google Colab ด้วยหน่วยประมวลผลกราฟิก NVIDIA T4 ส่วนตัวแปรและไฮเปอร์พารามิเตอร์ที่ใช้ควบคุมการทดลองแสดงดังตารางที่ 1: ทั้งนี้ ไม่ได้กำหนดค่า seed สำหรับกระบวนการฝึกสอนโมเดล (เช่น torch.manual_seed) ผลลัพธ์จึงอาจมีความแปรปรวนระหว่างการทดลองแต่ละครั้ง

ตารางที่ 1 การกำหนดค่าไฮเปอร์พารามิเตอร์สำหรับการทดลองเปรียบเทียบแบบจำลอง

พารามิเตอร์	แบบจำลอง LSTM (Baseline)	แบบจำลอง BERT (Fine-tuning)
สถาปัตยกรรมหลัก	Sequential RNN (LSTM)	Transformer Encoder (12-layer)
ขนาดแบทช์	32	16
อัลกอริทึมการหาค่าที่เหมาะสมที่สุด (Optimizer)	Adam	AdamW (Weight Decay = 0.01)
อัตราการเรียนรู้	1×10^{-3}	2×10^{-5}
ฟังก์ชันสูญเสีย	Cross-Entropy Loss	Cross-Entropy Loss
จำนวนรอบการฝึกสอน	5 รอบ	3 รอบ
ความยาวลำดับสูงสุด	128 โทเคน	128 โทเคน
สภาพแวดล้อมการทดลอง	Google Colab (NVIDIA T4 GPU)	Google Colab (NVIDIA T4 GPU)

3.5 เกณฑ์การประเมินประสิทธิภาพและตัวชี้วัด (Evaluation Metrics)

เพื่อประเมินศักยภาพการรู้จำรูปแบบและยืนยันข้อได้เปรียบทางโครงสร้างของแบบจำลอง การทดลองใช้เกณฑ์การประเมิน 2 มิติหลัก ดังนี้:

3.5.1 มิติด้านประสิทธิภาพการรู้จำรูปแบบ (Pattern Recognition Metrics)

ประเมินความสามารถในการจำแนกประเภทผ่านค่าความถูกต้องรวม (Accuracy) ซึ่งแสดงสัดส่วนของข้อมูลที่ทำนายถูกต้องทั้งหมด ควบคู่กับค่าความแม่นยำ (Precision) เพื่อวัดความแม่นยำในการระบุคลาสเป้าหมาย ค่าความไว (Recall) เพื่อวัดความครอบคลุมในการตรวจจับ และค่าคะแนนเฉลี่ยฮาร์โมนิก (F_1 -Score) เพื่อประเมินความสมดุลระหว่างความแม่นยำและความไว

3.5.2 มิติด้านประสิทธิภาพการคำนวณเชิงวิศวกรรม (Computational Efficiency Metrics)

ประเมินความคุ้มค่าเชิงทรัพยากรผ่านระยะเวลาการฝึกสอนเฉลี่ยต่อรอบ (Average Training Time per Epoch) เพื่อพิสูจน์ความสามารถในการประมวลผลแบบคู่ขนานของสถาปัตยกรรมบนฮาร์ดแวร์ GPU ควบคู่กับการติดตามอัตราการลู่เข้าของความสูญเสีย (Convergence Rate) จากการเปลี่ยนแปลงของค่า Cross-Entropy Loss ในแต่ละรอบการฝึกสอน

4. ผลการทดลองและการวิเคราะห์ผล

การทดสอบประสิทธิภาพเชิงเปรียบเทียบระหว่างแบบจำลองโครงข่ายประสาทแบบจดจำระยะสั้นยาว (LSTM) ในฐานะตัวแทนของกระบวนการที่ค้นเดิม และแบบจำลองภาษาเบิร์ต (BERT) ในฐานะตัวแทนของกระบวนการที่ค้นใหม่ ดำเนินการบนชุดข้อมูลทดสอบมาตรฐาน IMDb Review [4] ผ่านการประมวลผลบนหน่วยประมวลผลกราฟิก (GPU) ภายใต้สภาพแวดล้อมที่ควบคุมตัวแปรเดียวกันอย่างเคร่งครัด โดยสามารถจำแนกการวิเคราะห์ผลลัพธ์เชิงประจักษ์ออกเป็น 4 มิติสำคัญ ดังนี้:

4.1 ผลลัพธ์เชิงตัวเลขและตัวชี้วัดประสิทธิภาพ (Quantitative Performance Evaluation)

ผลการทดสอบการรู้จำรูปแบบบนชุดข้อมูลทดสอบที่ไม่เคยผ่านการฝึกสอนมาก่อน แสดงให้เห็นถึงความแตกต่างของขีดความสามารถอย่างชัดเจน โดยแบบจำลอง BERT มีประสิทธิภาพเหนือกว่าแบบจำลอง LSTM ในทุกมิติของตัวชี้วัด ดังแสดงในตารางที่ 2:

ตารางที่ 2 การเปรียบเทียบประสิทธิภาพการจำแนกประเภทข้อความระหว่างแบบจำลอง LSTM และ BERT จากการทดลองจริง

ตัวชี้วัดประสิทธิภาพ	แบบจำลอง LSTM (Baseline)	แบบจำลอง BERT (Fine-tuning)	ผลต่างการพัฒนา (Δ)
ความถูกต้อง (Accuracy)	55.20%	85.60%	+30.40%
ความแม่นยำ (Precision)	54.44%	83.72%	+29.29%
ความไว (Recall)	54.88%	87.80%	+32.93%
คะแนนเฉลี่ยฮาร์โมนิก (F_1 -Score)	54.66%	85.71%	+31.06%
เวลาฝึกสอนเฉลี่ยต่อรอบ (Time per Epoch)	0.82 วินาที	42.07 วินาที	+41.25 วินาที

จากตารางที่ 2 ข้อมูลเชิงประจักษ์ชี้ให้เห็นว่าแบบจำลอง BERT บรรลุค่าความถูกต้องรวม (Accuracy) ที่ร้อยละ 85.60 และค่าคะแนนเฉลี่ยฮาร์โมนิก (F_1 -Score) ที่ร้อยละ 85.71 ซึ่งมีประสิทธิภาพสูงกว่าแบบจำลอง LSTM ถึงร้อยละ 30.40 และ 31.06 ตามลำดับ ทั้งนี้ แบบจำลอง LSTM ซึ่งเริ่มต้นการเรียนรู้ใหม่ทั้งหมดจากศูนย์ (Training from Scratch) บนชุดข้อมูลขนาดจำกัด ทำคะแนนความถูกต้องได้เพียงร้อยละ 55.20 ซึ่งสูงกว่าการทายผลแบบสุ่ม (Random Guessing) ซึ่งมีความถูกต้องร้อยละ 50.00 อยู่เพียงเล็กน้อย ในขณะที่ BERT สามารถบรรลุค่าความไว (Recall) สูงถึงร้อยละ 87.80 แสดงถึงขีดความสามารถในการตรวจจับและระบุคลาสความคิดเห็นได้อย่างครอบคลุม

4.2 การวิเคราะห์อัตราการลู่เข้าและฟังก์ชันสูญเสีย (Loss Convergence Analysis)

เมื่อติดตามพฤติกรรมการลดลงของฟังก์ชันสูญเสีย (Cross-Entropy Loss) ในระหว่างกระบวนการฝึกสอน พบข้อสังเกตเชิงลึกที่สะท้อนถึงกลไกการเรียนรู้ของทั้งสองสถาปัตยกรรม ดังนี้:

4.2.1 พฤติกรรมการเรียนรู้ของแบบจำลอง LSTM

ค่าความสูญเสียของ LSTM ปรับลดลงอย่างต่อเนื่องจาก 0.6976 ในรอบแรก ลงมาอยู่ที่ 0.3234 ในรอบที่ 5 แม้ฟังก์ชันสูญเสียบนชุดข้อมูลฝึกสอนจะลดลงอย่างชัดเจน แต่ประสิทธิภาพบนชุดข้อมูลทดสอบกลับหยุดอยู่ที่ร้อยละ 55.20 ปรากฏการณ์นี้ชี้ให้เห็นถึงภาวะการเรียนรู้มากเกินไป (Overfitting) เนื่องจากแบบจำลองต้องพยายามสร้างเวกเตอร์แทนคำ (Embedding Space) ควบคู่ไปกับการเรียนรู้โครงสร้างประโยคจากข้อมูลปริมาณน้อย ส่งผลให้โครงข่ายจดจำเพียงคำสำคัญเฉพาะกลุ่มแต่ไม่สามารถสรุปบริบททั่วไปได้

4.2.2 พฤติกรรมการเรียนรู้ของแบบจำลอง BERT

แบบจำลอง BERT แสดงอัตราการลู่เข้าที่รวดเร็วกว่าอย่างเด่นชัด โดยเริ่มต้นรอบแรกด้วยค่าความสูญเสียเพียง 0.4826 และลดลงเหลือ 0.1369 ภายในระยะเวลาการฝึกสอนเพียง 3 รอบ ผลลัพธ์ดังกล่าวพิสูจน์ถึงข้อได้เปรียบของการถ่ายโอนการเรียนรู้ (Transfer Learning) จากการฝึกสอนล่วงหน้า (Pre-training) ซึ่งแบบจำลองมีโครงสร้างความเข้าใจทางภาษาและไวยากรณ์ที่สมบูรณ์อยู่แล้ว ทำให้การปรับจูนพารามิเตอร์เฉพาะงาน (Fine-tuning) เข้าสู่จุดเหมาะสมที่สุดได้อย่างรวดเร็วและมีเสถียรภาพสูง

4.3 การวิเคราะห์ประสิทธิภาพเชิงการคำนวณและความคุ้มค่า (Computational Efficiency and Trade-offs)

ในมิติของเวลาการคำนวณเชิงวิศวกรรม แบบจำลอง LSTM ใช้เวลาฝึกสอนเฉลี่ยเพียง 0.82 วินาทีต่อรอบ ขณะที่แบบจำลอง BERT ใช้เวลาเฉลี่ย 42.07 วินาทีต่อรอบ ซึ่งช้ากว่าประมาณ 51 เท่า ความแตกต่างนี้เป็นผลมาจากขนาดของพารามิเตอร์ที่ต่างกันอย่างมาก โดย BERT ประกอบด้วยพารามิเตอร์กว่า 110 ล้านตัว ผ่านชั้น Transformer Encoder ถึง 12 ชั้น ในขณะที่ LSTM มีพารามิเตอร์ประมาณ 4.04 ล้านตัว (ส่วนใหญ่มาจากชั้น Embedding ขนาด $30,522 \times 128$) อย่างไรก็ตาม เมื่อพิจารณาความคุ้มค่าระหว่างต้นทุนเวลาและประสิทธิภาพการรู้จำรูปแบบ การแลกเวลาการประมวลผลที่เพิ่มขึ้นเพื่อให้ได้ค่าความถูกต้องเพิ่มขึ้นถึงร้อยละ 30.40 ถือเป็นข้อได้เปรียบที่สำคัญยิ่งสำหรับระบบการรู้จำรูปแบบในทางปฏิบัติ

4.4 การวิเคราะห์ความผิดพลาดและข้อจำกัดเชิงโครงสร้าง (Qualitative and Error Analysis)

ผลต่างของประสิทธิภาพกว่าร้อยละ 30.40 ตอกย้ำถึงความเหนือกว่าของกระบวนทัศน์ใหม่ผ่านโครงสร้าง Self-Attention ใน 2 มิติสำคัญ ได้แก่:

4.4.1 การจัดการกับบริบทระยะไกล (Long-term Dependencies)

ในการจำแนกบทวิจารณ์ภาพยนตร์ที่มีความยาว ข้อความมักมีโครงสร้างที่ซับซ้อน เช่น การกล่าวถึงข้อความเชิงบวกในตอนต้นแต่หักมุมเป็นเชิงลบในตอนท้าย แบบจำลอง LSTM มีข้อจำกัดด้านการลดทอนของสารสนเทศตามลำดับเวลา (Context Decay) ทำให้ข้อมูลจากส่วนต้นประโยคสูญหายไปก่อนจะถึงหน่วยประมวลผลสุดท้าย ในขณะที่ BERT คำนวณความสัมพันธ์ระหว่างคู่คำทุกตำแหน่งพร้อมกัน จึงสามารถจับความหมายของประโยคหักมุมได้อย่างแม่นยำ

4.4.2 การเข้ารหัสบริบทแบบสองทิศทางที่แท้จริง (Bidirectional Representation)

คำศัพท์ที่มีความกำกวมหรือคำปฏิเสธ เช่น คำว่า not หรือ barely มักทำให้ LSTM สับสนเมื่อต้องประมวลผลจากซ้ายไปขวาทีละขั้นตอน แต่โครงสร้างของ BERT รับรู้บริบททั้งซ้ายและขวาพร้อมกัน ทำให้สามารถแยกแยะความหมายเชิงประตดประชันหรือการปฏิเสธซ้อนได้อย่างถูกต้อง ส่งผลให้เกิดความคลาดเคลื่อนในการจำแนกประเภทต่ำกว่าแบบจำลองเดิมอย่างชัดเจน

5. สรุปผลการทดลอง (Conclusion)

การทดลองเชิงเปรียบเทียบเพื่อศึกษาการเปลี่ยนผ่านของกระบวนการรู้จำรูปแบบ ระหว่างแบบจำลองโครงข่ายประสาทแบบจดจำระยะสั้นยาว (LSTM) ซึ่งเป็นตัวแทนของกระบวนการคิด กับแบบจำลองภาษาเบิร์ต (BERT) ซึ่งเป็นตัวแทนของกระบวนการคิดใหม่ ภายใต้ภารกิจการจำแนกความรู้สึกจากข้อความบนชุดข้อมูล IMDb [4] สามารถสรุปผลการวิจัยเชิงประจักษ์ได้ดังนี้

แบบจำลอง BERT มีประสิทธิภาพในการรู้จำรูปแบบเหนือกว่าแบบจำลอง LSTM อย่างชัดเจนในทุกตัวชี้วัด โดยทำค่าความถูกต้องรวม (Accuracy) ได้ร้อยละ 85.60 และค่าคะแนนเฉลี่ยฮาร์โมนิก (F_1 -Score) ร้อยละ 85.71 ซึ่งสูงกว่าแบบจำลอง LSTM ที่ทำได้เพียงร้อยละ 55.20 และ 54.66 ตามลำดับ คิดเป็นผลต่างความถูกต้องที่เพิ่มขึ้นถึงร้อยละ 30.40 ความแตกต่างดังกล่าวพิสูจน์ให้เห็นว่า กลไกความใส่ใจตนเอง (Self-Attention) แบบสองทิศทางของสถาปัตยกรรมทรานส์ฟอร์มเมอร์ สามารถแก้ปัญหาการลดทอนของสารสนเทศในลำดับข้อความขนานยาว (Long-term Dependencies) ได้อย่างสมบูรณ์ ต่างจาก LSTM ที่ประมวลผลข้อมูลตามลำดับเวลาและเกิดภาวะการเรียนรู้มากเกินไป (Overfitting) เมื่อต้องฝึกสอนจากศูนย์บนชุดข้อมูลขนาดจำกัด

ในมิติด้านประสิทธิภาพเชิงการคำนวณ แม้แบบจำลอง BERT จะใช้ระยะเวลาการฝึกสอนเฉลี่ยต่อรอบสูงกว่าแบบจำลอง LSTM (42.07 วินาที เทียบกับ 0.82 วินาที) เนื่องจากมีขนาดพารามิเตอร์มากกว่า 110 ล้านตัว แต่ด้วยกระบวนการถ่ายโอนการเรียนรู้ (Transfer Learning) จากการฝึกสอนล่วงหน้า ทำให้แบบจำลอง BERT สามารถเข้าสู่จุดที่เหมาะสมที่สุดได้ภายในระยะเวลาเพียง 3 รอบการฝึกสอน ซึ่งน้อยกว่า LSTM ที่ต้องใช้เวลารอบถึง 5 รอบ ดังนั้น การแลกเปลี่ยนทรัพยากรการคำนวณและเวลาที่เพิ่มขึ้นกับระดับความถูกต้องที่ก้าวกระโดดกว่าร้อยละ 30.40 จึงถือเป็นความคุ้มค่าเชิงวิศวกรรม และเป็นการยืนยันความสำเร็จของการเปลี่ยนผ่านสู่กระบวนการคิดใหม่ในระบบการรู้จำรูปแบบอย่างแท้จริง

เอกสารอ้างอิง

- [1] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [2] A. Vaswani et al., "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, pp. 5998–6008, 2017.
- [3] J. Devlin, M. W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. NAACL-HLT*, pp. 4171–4186, 2019.
- [4] A. L. Maas et al., "Learning word vectors for sentiment analysis," in *Proc. 49th Annual Meeting of the ACL*, pp. 142–150, 2011.
- [5] T. Wolf et al., "Transformers: State-of-the-art natural language processing," in *Proc. EMNLP: System Demonstrations*, pp. 38–45, 2020.