

กระบวนการทัศน์ใหม่ ของการรู้จำรูปแบบ

จาก LSTM คู่ Transformer — การเปรียบเทียบเชิงประจักษ์
บนงานจำแนกความรู้สึก (Sentiment Analysis) ชุดข้อมูล IMDb

ชื่อผู้จัดทำ ชยุตม์ อยู่เจริญกิจ

รหัสนักศึกษา 67543206046-4

รายวิชา / กลุ่มเรียน ENGCE408_SEC1

อาจารย์ผู้สอน ผศ.ดร.สมนึก สุระรง

ภาคการศึกษา 1/2569



มหาวิทยาลัยเทคโนโลยี

ราชมงคลล้านนา เชียงใหม่

RMUTL CHIANG MAI

01 · ที่มาและความสำคัญของปัญหา

Why sentiment analysis still matters

- ▶ ความคิดเห็นนับล้าน ถูกเขียนขึ้นทุกวันบนแพลตฟอร์มออนไลน์ — ธุรกิจต้องรู้ว่าลูกค้า "รู้สึก" อย่างไรกับสินค้าและบริการ
- ▶ โมเดลคลาสสิกอย่าง **LSTM** เคยเป็นมาตรฐานของงานประมวลผลภาษา แต่มีข้อจำกัดเชิงโครงสร้างที่แก้ไขยาก
- ▶ **Transformer** และ **BERT** เปลี่ยนกระบวนการทัศน์ด้วยกลไก **self-attention** — งานวิจัยนี้พิสูจน์ด้วยตัวเลขจริงว่าต่างกันแค่ไหน

คำถามงานวิจัย

เมื่อให้ LSTM และ BERT ที่ผ่านการ **fine-tune**

ทำโจทย์เดียวกัน — จำแนกความรู้สึกของรีวิว

ภาพยนตร์ **IMDb** — ฝ่ายใดแม่นยำกว่า

และต้องแลกมาด้วยต้นทุนเท่าไร?


ขอบเขต: จำแนกแบบทวิภาค (บวก/ลบ) · ชุดข้อมูลสมดุล · วัดผลด้วย Accuracy, Precision, Recall, F1

ศัพท์น่ารู้ ทวิภาค (**binary**) = แบ่ง 2 กลุ่ม บวก/ลบ · **IMDb** = ชุดข้อมูลรีวิวภาพยนตร์

02 · LSTM: หน่วยความจำแบบวนซ้ำ

Long Short-Term Memory — the recurrent baseline

อ่านประโยคทีละคำจากซ้ายไปขวา



LSTM อ่านทีละคำ ส่งต่อความจำทีละขั้น — ประโยคที่ยาว ข้อมูลจากต้นประโยคยิ่งสูญหายไประหว่างทาง

จุดอ่อนเชิงโครงสร้าง

- ▶ ประมวลผลแบบลำดับขั้น — ขนานไม่ได้ ช้าบนข้อมูลยาว
- ▶ ความจำระยะยาวเลื่อม — บริบทไกล ๆ หลุดหาย
- ▶ มองเห็นแค่ "อดีต" — ไม่รู้บริบทด้านขวาของคำ

ศัพท์น่ารู้ **hidden state** = สถานะความจำภายในโมเดล · **vanishing gradient** = เกรเดียนต์จางหายระหว่างฝึก

03 · Transformer: มองเห็นทั้งประโยคพร้อมกัน

Self-attention — the paradigm shift

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

เมื่อคำนวณกับทุกโทเค็นในลำดับ โมเดลจะรู้ว่าคำไหนควร “สนใจ” คำไหน — ไม่ว่าจะอยู่ห่างกันแค่ไหน

ไม่ต้องวนซ้ำ

ประมวลผลทุกตำแหน่งพร้อมกัน

ขนานได้เต็มที่บน GPU

บริบทสองทิศทาง

แต่ละคำมองเห็นทั้งประโยค

ซ้ายและขวาในครั้งเดียว

ความสัมพันธ์ระยะไกล

คำที่ห่างกันหลายสิบคำ


ยังเชื่อมโยงกันโดยตรง

ยกเลิกโครงสร้างวนซ้ำทั้งหมด → เหลือเพียง attention ส่วน ๆ — นี่คือหัวใจของ BERT

ศัพท์น่ารู้ **self-attention** = กลไกให้น้ำหนักความสำคัญระหว่างคำ · **Q / K / V** = สามเวกเตอร์คำถาม—คีย์—ค่า

04 · BERT และการทำ Fine-tuning

Pre-train once, adapt to the task




Pre-train บนข้อความมหาศาลมาก่อน → **Fine-tune** เพียง 3 รอบบน IMDb ก็พร้อมใช้งาน — ไม่ต้องฝึกตั้งแต่ศูนย์

ศัพท์น่ารู้ [CLS] = โทเคนพิเศษแทนความหมายทั้งประโยค · **fine-tuning** = ฝึกลดข้อผิดพลาดจากโมเดลสำเร็จรูป

05 · กระบวนการทดลอง

Experimental pipeline — same data, same task, fair test



ควบคุมตัวแปรครบถ้วน: ข้อมูลชุดเดียวกัน แบ่งด้วย **seed 42** ความยาวสูงสุด 128 โทเค็น — สิ่งที่แตกต่างกันเพียง "สถาปัตยกรรมโมเดล"

ภาพรวมการทดลอง: ข้อมูล → ฝึกสอน → ประเมินผล

ศัพท์น่ารู้ **seed 42** = ค่าคงที่ให้การสุ่มซ้ำได้เหมือนเดิม · **batch** = กลุ่มข้อมูลที่ฝึกพร้อมกันในหนึ่งขั้น

06 · การตั้งค่าการทดลอง

Hyperparameters — every knob on the table

พารามิเตอร์	LSTM	BERT (bert-base-uncased)
Embedding dim	128	768
Hidden size	128	768 ([CLS])
จำนวนรอบฝึก	5	3
Batch size	32	16
Learning rate	1×10^{-3}	2×10^{-5}
Optimizer	Adam	AdamW + weight decay 0.01
Dropout	—	0.10
พารามิเตอร์รวม	~4.04 ล้าน	~110 ล้าน

ข้อมูล

2,000 ฝึก · 500 ทดสอบ


สภาพแวดล้อม

Google Colab · NVIDIA T4
PyTorch + Hugging Face

ศัพท์น่ารู้ **learning rate** = ขนาดก้าวในการปรับน้ำหนัก · **weight decay** = ลงโทษน้ำหนักมาก ป้องกัน **overfit**

07 · ผลการทดลอง: ตัวเลขไม่โกหก

Head-to-head results on the 500-sample test set



เมตริกทั้งหมดคำนวณบนชุดทดสอบ 500 ตัวอย่าง

ความแม่นยำ Accuracy

BERT 85.60%

LSTM 55.20% → Δ +30.40 จุด

ความเที่ยง Precision

BERT 83.72%

LSTM 54.44% → Δ +29.28 จุด

ความระลึก Recall


BERT 87.80%

LSTM 54.88% → Δ +32.92 จุด

ศัพท์น่ารู้ **precision** = ทายบวกแล้วถูกกี่ % · **recall** = ของบวกจริง จับได้กี่ %

08 · เส้นทางการเรียนรู้

Training loss: first vs final epoch



LSTM: 0.6976 → 0.3234

ลด **53.6%**

loss ลดลงต่อเนื่อง แต่ค้างที่ระดับสูง — โมเดลเรียนรู้ได้จำกัด

BERT: 0.4826 → 0.1369

ลด **71.6%**

เริ่มต่ำกว่าและลงลึกกว่า — ความรู้จาก pre-training ต่อยอดได้ทันที

เปรียบเทียบเฉพาะค่ารอบแรกและรอบสุดท้ายที่รายงานไว้จริง ไม่มีการประมาณค่ากลาง

ศัพท์น่ารู้ **loss** = ค่าความผิดพลาด ยิ่งต่ำยิ่งดี · **converge** = เข้าสู่ค่าคงที่เมื่อฝึกนานพอ

09 · เมื่อใดที่ LSTM พลาด

Error analysis — where recurrence breaks down

ประโยคเชิงซ้อน

"The movie was not bad, but the ending was barely watchable."

- ▶ **LSTM:** อ่านซ้าย→ขวาทีละชั้น สืบค้นกับการปฏิเสธซ้อนและความกำกวม
- ▶ **BERT:** รับรู้บริบทสองทิศทางพร้อมกัน แยกแยะความหมายได้แม่นยำกว่า

คำปฏิเสธและคำกำกวม


not · barely

- ▶ **LSTM:** อ่านซ้าย→ขวาทีละชั้น สืบค้นกับการปฏิเสธซ้อนและความกำกวม
- ▶ **BERT:** รับรู้บริบทสองทิศทางพร้อมกัน แยกแยะความหมายได้แม่นยำกว่า

ศัพท์น่ารู้ การปฏิเสธซ้อน = คำปฏิเสธหลายชั้น · บริบทสองทิศทาง = มองซ้าย—ขวาของคำพร้อมกัน

10 · ความแม่นยำ VS ต้นทุน

The engineering trade-off



LSTM 0.82 วินาที — แท่งเล็กจนแทบมองไม่เห็นเมื่อเทียบกับสเกลเดียวกับ BERT

ต้นทุนที่จ่าย

51× ช้ากว่า ต่อรอบการฝึก

0.82 → 42.07 วินาที/รอบ

แลก

สิ่งที่ได้กลับมา

+30.40 จุดความแม่นยำที่เพิ่มขึ้น

55.20% → 85.60% · F1 54.66% → 85.71%

จ่ายเวลาประมวลผลเพิ่มขึ้น **~51 เท่า** แลกความแม่นยำที่ก้าวกระโดด **+30.40 จุด** — คุ่มค่าเชิงวิศวกรรม

ศัพท์น่ารู้ รอบการฝึก (epoch) = โมเดลเห็นข้อมูลฝึกครบ 1 ครั้ง · F1 = คะแนนรวม precision และ recall เข้าด้วยกัน

11 · บทสรุป

What the numbers prove

BERT ขนาดทุกเมทริก

ความแม่นยำ 85.60% เทียบกับ 55.20% — ต่างกัน 30.40 จุด

ความรู้จาก **pre-training** คือตัวแปรสำคัญ

ไม่ต้องเริ่มนับหนึ่งใหม่บนงานเฉพาะทาง

LSTM ไม่ไร้ค่า

เร็วกว่า ~51 เท่าต่อรอบ — ยังเหมาะกับงานที่ทรัพยากรจำกัด

ข้อจำกัดของงานวิจัย

ชุดข้อมูล 2,000 ตัวอย่าง โดเมนเดียว — ผลอาจต่างบนโดเมนอื่น

ศัพท์น่ารู้ **pre-training** = ฝึกพื้นฐานบนข้อมูลมหาศาลมาก่อน · **โดเมน** = ขอบเขตหรือประเภทของข้อมูล

12 · เอกสารอ้างอิง

References

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.

Vaswani, A., et al. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.

Devlin, J., et al. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *NAACL-HLT*.

Maas, A. L., et al. (2011). Learning word vectors for sentiment analysis. *ACL-HLT*.

Wolf, T., et al. (2020). Transformers: State-of-the-art natural language processing. *EMNLP (demo)*.